



#26 - Basic of RNN

주제 : Basic of RNN (Recurrent Neural Network)

링크 :

[#26.Lec] (강추) Basic of RNN (Recurrent Neural Network) - 딥러닝 홀로서기

강의 자료 링크 : <https://github.com/heartcored98/Standalone-DeepLearning/blob/master/Lec7/Lec7-A.pdf> 자료 저장소 링크 : <https://github.com/heartcored98/Standalone-DeepLea...>

 <https://youtu.be/bPRfnIG6dtU>



1. Dealing with Sequential Data

- 만약 상사가 다음 4가지 문제를 내주었을때,

- ① 이미지를 주고 **캡션**을 자동적으로 매기는 것
- ② 기업이 **파산**할지 아닐지 예측
- ③ **문장**을 해석해서 다른 언어로 번역
- ④ 문장을 주고 각 토큰의 품사를 알아 맞추는 것 (Multi-label Classification)

→ 이 모든 문제의 특징은, Sequential Data를 다루는 문제라는 공통점을 가지고 있다

*** Sequential Data (순차 데이터) : 말, 텍스트, 이미지 등 순서(Order)가 있는 데이터**

- Type of Task Dealing with Sequential Data

- RNN으로 풀 수 있는 문제는 다음의 4가지이며, 문제를 풀기 전 어떤 유형인지 파악

- One to One

- X_1, X_2 를 주고 Y 를 예측하는 것, 이미지를 주고 무슨 Class인지 예측하는 것

- One to Many

- ① 이미지를 주고 캡션을 생성하는 문제

→ 이미지를 CNN모델을 통해서 Feature Vector를 생성하여 이미지로 부터 자연어를 매핑

- Many to One

- ② Bankruptcy될지 안될지를 예측하는 문제

→ Discrete한 Time Step을 보고 Sequence에 대한 Feature Vector를 생성하여 Binary Classification

- Many to Many


- ③ 문장을 해석하여 (단어1, 단어2, 단어3) 다른 언어로 번역하는 문제

→ 문장의 각 단어에 대한 Feature Vector를 생성하여 다른 언어 스페이스에서 매핑

- Many to Many

- ④ 단어1(W_1), 단어2(W_2), 단어3(W_3)의 품사를 알맞추는 문제

→ 입력된 Input : 각 단어 (W_1, W_2, W_3)에 대해서 Time Step별로 Task 수행



2. Classical Approach for Time Series Analysis

- Time Series Analysis를 푸는 기존의 방식
 - Time domain analysis
 - 파형을 보고, 폭, 움직임, 파형의 높이를 보고 분석
 - Frequency domain analysis
 - Fourier transformation (주파수 대역(스펙트럼) 변형)을 하거나, Wavelets을 하는것
 - Nearest neighbors analysis
 - Dynamic time warping (DTW) 알고리즘, Sequential한 데이터끼리 어떻게 Similarity를 측정할 것인가에 대한 방식
 - Probabilistic Model
 - 주어진 시퀀스에 대해서 그 다음에 나올 값이 무엇인지 확률적으로 예측하는 모델
 - (S)AR(I)MA(X) models
 - 통계적 방식으로 시계열 내에 Auto Correlation이 있는지 확인하는 것
 - Decomposition
 - 전체적인 트렌드 + 주기적으로 변동하는 항목 + 오류의 합으로 Time Series가 만들어져 있다고 가정하여 각각의 항목을 Time Series로부터 분해하는 방식
 - Nonlinear Dynamics
 - 미분 방정식을 활용하여 변화하는 시스템을 편미분하는 모델
 - Machine Learning
 - 위에서 나온 기법들을 통해서 Feature들을 머신러닝 기법으로 Regression, Classification하는 방식
- Deep Learning은 위와 같은 기존의 Time Series Analysis 방식처럼 Manual로 각각의 Feature를 구하여 분석하는 방식이 아닌, 알아서 Feature를 구하여 Regression, Classification하기 위하여 사용함

3. Deep Learning Dealing with Sequential Data

- 지금까지 배운 Deep Learning 방식으로 Sequential Data 문제를 풀수 있을까?
 - MLP
 - Fully Connected Layers를 켜켜이 쌓아놓는 방식임
 - w matrix가 고정되어 있기에, 따라서 임의의 길이의 sequential를 다루기가 어려움
 - w 차원에 맞추어 resize하던지, 차원을 축소, 확장해야 하기 때문에 정보의 손실이 발생
 - 다양한 파형이 있을 수 있는데, 그 파형을 파악하기 위한 파라미터가 굉장히 많이 필요
 - CNN
 - Convolution + Pooling + Fully Connected Layers를 쌓아놓는 방식

- Time Series Analysis가 수월하게 동작한다 (하단 링크에 설명)

Convolutional Neural Networks for Multi-Step Time Series Forecasting - Machine Learning Mastery

Given the rise of smart electricity meters and the wide adoption of electricity generation technology like solar panels, there is a wealth of electricity usage data available. This data represents a multivariate time series of power-related variables that in turn could be used to model and even forecast future electricity consumption.

<https://machinelearningmastery.com/how-to-develop-convolutional-neural-networks-for-multi-step-time-series-forecasting/>




- CNN이 나오기 전, 이런 Sequential Data처리를 위해 RNN을 만들어냈음


4. Recurrent Neural Network

- 개념

- Sequence Data를 분석할 때 Time Step T에서의 입력된 Input을 처리하고 Output을 내보낼 때, 전후 관계는 고려되지 않는 것 문제가 발생됨
- 따라서 이전 Step에서 나온 Output과 현재 상태에서의 Input을 함께 고려하여 현재 Step에서 Output을 새롭게 만들자는 것이 핵심
- 예시) $Input X_t$ 를 모델에 넣어 h_t 를 Output으로 도출하여 이를 다시 X_{t+1} 과 함께 모델의 Input값으로 입력하여 최종적으로 $h_{t+1}, h_{t+2}, h_{t+3}$ 까지 도출



- 위의 Sequence(전후관계) Featurizing 을 구체적으로 설명하자면,
 - ① 짙은 초록색 박스 : $Input X_t$ 를 모델에 통과시켜 벡터를 생성(Linear Transformation하면(=wx)차원이 Projection되는 것과 같은 원리)
 - ② 짙은 파란색 박스 : h_{t-1} 을 0 또는 랜덤으로 초기화하여 동일한 Dimension(h_{t-1} 의 요소가 100개라면 100 x 100)의 Matrix를(=w) 곱해서 해당하는 Hidden Vector를 생성
 - ③ 초록 박스 + 파란 박스 : Elementwise(요소끼리) 더하여 이를 Non-Linear Activation Function을(Sigmoid, hipertangent, ReLu 등) 취해준다
 - ④ 이 결과값을 Time Step T에서의 h_t 로 활용함
 - ⑤ ④의 결과값을 활용하여 ①②③④ 순서대로 다시 수행하여 $h_{t+1}, h_{t+2}, h_{t+3}$ 까지 도출



Q1. h 를 바로 사용하지 않고 행렬을 곱해서 사용하는 이유는?

- H 값은 이전 Step의 결과물이고, 이를 Non-Linear Activation에 활용할 형태로 변형해서 사용해야 하기 때문에 정방행렬을 곱하여 Non-Linear한 형태로 변환하는 것임

Q2. 입력되는 데이터 길이가 다르다면 어떻게 처리해야 하나요?

- 입력 데이터의 길이가 다르다면, 처리가 안될 것이다. 따라서 데이터를 정비하여(Interpolation) 데이터의 형태를 정비한 후 수행해야 한다

Q3. 데이터가 문장이면 어떻게 처리해야 하나요?

- 전체 문장에 대한 Vocabulary set을 만들어서 각 토큰을 One-Hot Encoding으로 표현


ex) I Have Apple \rightarrow I, Have, Apple \rightarrow Vocabulary Set : 3 $\rightarrow X_t : 100 \rightarrow X_{t+1} : 010 \rightarrow X_{t+2} : 001$ 으로 표현

Q4. 문맥상 같은 단어의 의미차이는 어떻게 고려하나요?

- Contexturizing Embed 방법으로 주위 단어의 맥락을 보고 해당 단어를 Vector를 어떻게 잘 만들것인가 \rightarrow '엘모어, 트랜스포머, 벌트'의 키워드로 검색해서 공부해보아~

• Many to One


- Sequence Length가 3인 Sequence라 가정하면, 위의 모델에서 마지막 h 에 원하는 모델 하나만 새로 붙이면 됨



• Many to Many

- 각각의 h_t 에 파라미터가 동일한 모델을 씌워서 계산하여 Loss를 바탕으로 업데이트를 한 후, Y_t, Y_{t+1}, Y_{t+2} 를 도출

※ 업데이트 : Binary Classification 문제라면 각 모델에서 도출된 Loss를 합산하여 이를 바탕으로 Backpropagation으로 Gradient를 계산하여 Optimizing하면 파라미터가 업데이트됨



- Many to Many

- 위의 예에서 다른 언어로 번역하는 과정을 Many to Many로 보자면,


- "I Have Apple"을 한글로 번역하는 과정으로 예를 들자

① Encoding Process


- "I Have Apple"을 각각 Vocabulary Set으로 분류하여 Feature Vector를 생성하는 과정

② Decoding Process


- 마지막 모델을 통하여 $Y_{T+2} = \text{"나는"}$ 이라는 단어를 예측




- 예측한 Y_{T+2} 와 이전 단계의 h_{T+2} 를 Input 값으로 활용




- 모델을 통하여 다시금 Y_{T+3} = "가졌다"라는 단어를 예측



- 마지막 모델을 통하여 Y_{T+4} = "사과"라는 단어를 예측



- 최종적으로 Cross Entropy를 활용하여 True Y와의 Loss를 계산하여 모델을 평가
- 주의점
 - Encoding Process와 Decoding Process에서 사용하는 파라미터가 다르다
 - 영어로부터 Feature Vector를 추출하는 모델과, 영어로부터 한글을 생성시키는 모델이기 때문
 - 이는 곧, h_{t+2} 로부터 의미는 공유되 각각의 Language Space는 각각 다르다는 것이다
- One to Many
 - 이미지가 어떤 클래스인지 알아내는 과정
 - (Encoding) CNN을 통과한 이미지 벡터를 x_{t+2} 에 입력하여 Decoding과정을 거치면 클래스를 판별할 수 있음




Q. Sequence 길이가 다르면 어떻게 처리 하나요?

- 1) Max Sequence Length를 정해놓고 Sequence를 작성 (Max보다 길면 끊어서)
- 2) 동시에 Batch 갯수의 Sequence를 처리할 수 있으니 Forward를하다가 먼저 끝나는 순서대로 문장을 리스트에 입력하는 방식 (문장의 앞과 뒤에 (BOS : begin of sentence, EOS : end of sentence 토큰을 넣어줌)

5. Recurrent Neural Network with Math

- 수학적 해석 과정
 - $h_{t+2} = f(Ux_t + Wh_{t-1})$
 - $Input X_{t+2}$ 을 U로 Projection 한 후, h_{t-1} 을 W로 Projection 한 후 Element wise하게 합산
 - Non-Linear Activation Function f를 적용
 - $f(x) = \tanh(x)$
 - 위에서 사용한 f 함수는 RNN에서 보통 $\tanh(x)$ 를 주로 사용함 (-1 ~ 1사이의 값)
 - $y_t = f(Vh_t)$
 - Y는 V라는 파라미터를 통해서 Projection시킨 후 f를 적용
 - $f(x) = x$
 - Y_{t+2} 에서 사용한 f 함수는 문제, 기호에 따라서 원하는 모델을 사용 (Linear Regression, Logistic Regression, MLP 등 등)




6. How can we evaluate it?

- 평가 방식
 - True Y와 Pred Y의 Loss를 구하여 평균을 구함
 - 각 시퀀스 별로 계산하여 마지막 Loss 값을 통하여 Backward 하면 미분값을 통하여 업데이트
 - 마지막 Task가 Classification이라면 Loss 함수를 CrossEntropy로 사용
 - 마지막 Task가 Regression이라면 Loss 함수를 MSE로 사용

$$Loss(\theta) = \sum_t loss(y_{true,t}, y_{pred,t})$$

Classification → CrossEntropy

Regression → MSE



Q. Gradient Vanishing 문제는 어떻게 해결하는가?

- 이를 해결한 모델이 LSTM이다!

7. Summary

- 다양한 Task에서는 Sequential data를 사용해야 한다

- RNN은 이를 쉽게 해결한다
- 기본적으로 RNN은 새로운 Input과 이전 Step의 Output을 활용하는 것이 핵심
- RNN을 활용하여 다양한 Task (one to one, many to one, many to many)를 해결가능